

SEMICONDUCTOR PROJECT WORKFLOW

แนวทางดำเนินโครงการด้วย Pandas, Matplotlib และ Codex ใน Visual Studio Code

จาก Raw Data สู่ Data Preprocessing, EDA, Visual Storytelling และการเผยแพร่บน
GitHub

DADS5001 Mid-Term Project

1. ภาพรวมโครงการ

Workflow หลักของโครงการควรเดินจากคำถามวิจัยไปสู่ข้อมูลดิบ การตรวจสอบและเตรียมข้อมูล การวิเคราะห์เชิงสำรวจ การสร้างกราฟเพื่อสื่อสาร และการเผยแพร่ผลอย่างทำซ้ำได้บน GitHub



หัวข้อชั่วคราว

AI Boom and the Semiconductor Value Chain: Who Captures the Growth?

คำถามหลัก: หลังการเติบโตของ AI ตั้งแต่ประมาณปี 2022 บริษัทและกลุ่มธุรกิจใดได้รับประโยชน์มากที่สุด และการเติบโตนั้นสัมพันธ์กับ R&D, CapEx, กำลังผลิต และราคาซื้ออย่างไร?

คำถามย่อย

- รายได้ของกลุ่มธุรกิจใดเติบโตเร็วที่สุดหลังปี 2022?
- บริษัทที่รายได้เติบโต ลงทุน R&D; หรือ CapEx เพิ่มขึ้นหรือไม่?
- กำลังผลิต Leading-edge กระจุกตัวในบริษัทและประเทศใด?
- ราคา HBM3, H100 และ B200 เปลี่ยนไปอย่างไร?
- เหตุการณ์ด้าน Export Control เกิดขึ้นพร้อมกับความเปลี่ยนแปลงของราคาและกำลังผลิตอย่างไร?
- การเติบโตกระจายหัวอุตสาหกรรมหรือกระจุกตัวในบริษัทไม่กี่ราย?

หลักการสื่อสาร: ใช้คำว่า “สัมพันธ์กับ” หรือ “เกิดขึ้นในช่วงเดียวกัน” แทนการสรุปเหตุและผลที่ข้อมูลยังพิสูจน์ไม่ได้

2. ขั้นที่ 1 - กำหนดโจทย์และขอบเขต

ก่อนเขียนโปรแกรม ให้สร้าง PROJECT_PLAN.md เพื่อยืนยันว่าคำถาม ตัวแปร และช่วงเวลาตอบกันได้

สิ่งที่ต้องระบุ

- ชื่อโครงการและที่มาของปัญหา
- Research question และคำถามย่อย
- ช่วงเวลาที่ศึกษาและเหตุผลที่เลือก
- Dataset ที่ใช้และบทบาทของแต่ละไฟล์
- ตัวชี้วัดหลัก เช่น Revenue Growth, R&D; Intensity, CapEx Intensity, Price Change และ Capacity Share
- สิ่งที่ไม่อยู่ในขอบเขต เช่น การพิสูจน์เหตุและผลหรือการพยากรณ์ด้วย Machine Learning
- ข้อจำกัดที่ทราบล่วงหน้า เช่น Estimated values และข้อมูลปี 2026

ขอบเขตเวลาที่แนะนำ

Dataset	ช่วงข้อมูล	บทบาท
Financials	2010-2026	แนวโน้มรายได้ ค่าไร R&D; และ CapEx
Chip Prices	2014-04/2026	แนวโน้มและความผันผวนของราคา
Export Controls	2018-2026	Timeline เชนนโยบาย
Fab Capacity	2011-2026	กำลังผลิตตามประเทศ บริษัท และ node
AI Chip Market	2020-2026	Estimated shipments, ASP และ revenue

เพื่อเปรียบเทียบก่อนและหลัง **AI Boom** สามารถกำหนดช่วง **2018-2021** เป็น **Pre-AI boom** และ **2022-2026** เป็น **AI boom** ได้ แต่ต้องระบุว่าเป็นนิยามที่ **Project** กำหนดเอง

3. ขั้นที่ 2 - สร้าง GitHub Repository

Repository ควรทำให้ผู้อื่น Clone แล้วรันงานได้โดยไม่ต้องแก้ path จากเครื่องของผู้จัดทำ

```
semiconductor-ai-value-chain-analysis/
|-- README.md
|-- LICENSE
|-- requirements.txt
|-- .gitignore
|-- data/
|   |-- raw/                # ██████████ ██████████
|   |-- processed/          # ████████████████████
|-- notebooks/
|   |-- 01_data_audit.ipynb
|   |-- 02_data_preprocessing.ipynb
|   |-- 03_eda_financials.ipynb
|   |-- 04_eda_prices_capacity_policy.ipynb
|   |-- 05_final_storytelling.ipynb
|-- src/
|   |-- data_cleaning.py
|   |-- feature_engineering.py
|   |-- visualization.py
|-- figures/
|-- docs/
|   |-- data_dictionary.md
|   |-- methodology.md
|   |-- limitations.md
```

ไฟล์ requirements.txt เบื้องต้น

```
pandas
matplotlib
jupyter
```

ห้ามใช้ Absolute path เช่น D:/Andrew Drive D:/... ใน Notebook ที่จะเผยแพร่ ให้ใช้ Path แบบสัมพันธ์กับโครงสร้าง Repository

```
from pathlib import Path
import pandas as pd

ROOT = Path.cwd().parent
RAW_DIR = ROOT / 'data' / 'raw'
financials = pd.read_csv(RAW_DIR / 'chip_companies_financials.csv')
```

4. ขั้นที่ 3 - Raw Data และ Data Audit

เก็บไฟล์ต้นฉบับทั้งหมดใน data/raw/ และห้ามแก้ไขหรือเขียนทับ จากนั้นใช้ 01_data_audit.ipynb ตรวจสอบคุณภาพก่อนตัดสินใจทำความสะอาด

รายการตรวจสอบขั้นต่ำ

```
df.shape
df.head()
df.tail()
df.info()
df.describe(include='all')
df.isna().sum()
df.duplicated().sum()
df.nunique()
```

ต้องตรวจเพิ่มเติม

- ช่วงปี จำนวนบริษัท จำนวนผลิตภัณฑ์ และค่าที่พบใน Category
- ค่าติดลบ ค่าศูนย์ Outlier และการแปลงชนิดข้อมูล
- Primary key ซ้ำ เช่น year + company_name หรือ year_month + product
- ความสอดคล้องระหว่าง year กับวันที่ และสูตรที่คำนวณย้อนกลับได้
- ความหมายของศูนย์ว่าเป็นค่าจริง ไม่มีข้อมูล หรือยังไม่เริ่มดำเนินงาน

Data Quality Summary ที่ควรสร้าง

Dataset	Rows	Missing	Duplicate	ประเด็นสำคัญ
Financials	617	0	0	ตัวเลขบางชุดคล้ายสร้างจากสูตร
Prices	405	0	0	ไม่ทราบว่าเป็น Spot, Contract หรือ ASP
Export controls	34	0	0	Severity ไม่มีเกณฑ์และมีจุดไม่สอดคล้อง
Fab capacity	313	0	0	ไม่ระบุขนาดเวเฟอร์ สถานะโครงการ หรือ utilization
AI chip market	120	0	0	Shipments, ASP และ revenue เป็น estimated

5. ขั้นที่ 4 - Data Preprocessing

เป้าหมายคือทำให้ข้อมูลสะอาดและมีโครงสร้าง โดยเก็บ Raw values ไว้ ตรวจสอบทุก Transformation และไม่ลบแถวที่น่าสงสัยโดยอัตโนมัติ

Financials

- แปลง year และคอลัมน์ตัวเลขด้วย `pd.to_numeric(errors='coerce')`
- สร้าง parent_company เพื่อเชื่อมต่อ เช่น Samsung Foundry และ Samsung Memory แต่ไม่รวมรายได้ทันทีเพื่อป้องกัน Double counting
- ตรวจสอบ operating_income กับ $\text{revenue} \times \text{operating_margin}$
- แยก Actual กับ Forecast หากมีข้อมูลรองรับ

Prices

- แปลง year_month ด้วย `pd.to_datetime(format='%Y-%m')`
- ตรวจสอบว่า year ตรงกับปีที่ดึงจาก year_month
- เก็บ unit แยกชัดเจน และไม่รวม USD/chip, USD/stack และ USD/unit บนแกนราคาเดียวกัน

Export controls

- แปลง date ด้วย `dayfirst=True`
- สร้าง year_month เพื่อเชื่อมกับราคาชิปรายเดือน
- เพิ่ม policy_direction เช่น tighten, relax, subsidy, investigation, agreement
- เพิ่ม target_type เช่น company, technology, material, country, policy
- ตรวจสอบแต่ละเหตุการณ์ด้วยคน ไม่ให้ Codex เดาคความหมายเอง

Fab capacity และ AI chip market

- สร้าง years_since_start และ annualized_capacity โดยระบุว่าไม่ใช่ Actual production
- สร้าง technology_group ด้วยเกณฑ์ที่บันทึกไว้ใน Methodology
- แปลง launch_date และตรวจสอบ $\text{estimated revenue} = \text{shipments} \times \text{ASP}$
- เก็บคอลัมน์ค่าเตือน เช่น is_estimated หรือ data_status หากจำแนกได้

6. ขั้นที่ 5 - Data Validation

ก่อนเริ่ม EDA ต้องมี Validation Cell เพื่อให้ Notebook หยุดเมื่อพบข้อมูลผิดเงื่อนไขสำคัญ

```
assert financials['year'].between(2010, 2026).all()
assert prices['price'].ge(0).all()
assert controls['severity_score'].between(0, 10).all()
assert capacity['monthly_wafer_capacity'].ge(0).all()
```

Quality gate ก่อนเข้า EDA

- วันที่และตัวเลขแปลงสำเร็จ
- ไม่มี Primary key ซ้ำ
- ไม่มีค่าติดลบที่ขัดกับความหมายของตัวแปร
- Missing ที่เกิดหลังแปลงได้รับการรายงาน
- ทุกการแก้ไขมีเหตุผลและจำนวนแถวก่อน-หลัง
- รายการที่น่าสงสัยถูก Flag ไม่ถูกลบทิ้งอย่างเจียม ๆ

ตัวอย่างตรวจ Operating Income

```
financials['operating_income_check'] = (
    financials['revenue_usd_bn']
    * financials['operating_margin_pct'] / 100
)
financials['operating_income_diff'] = (
    financials['operating_income_usd_bn']
    - financials['operating_income_check']
).abs()
```

7. ชั้นที่ 6 - Feature Engineering

สร้างตัวชี้วัดที่ตอบคำถามวิจัย โดยระบุสูตร หน่วย และวิธีจัดการศูนย์หรือ Missing value

Metric	สูตร/แนวคิด	ใช้ตอบคำถาม
Revenue Growth	pct_change() ตามบริษัท	บริษัทใดโตเร็วที่สุด
R&D; Intensity	R&D; / Revenue x 100	ใครลงทุนด้านนวัตกรรมเพิ่มขึ้น
CapEx Intensity	CapEx / Revenue x 100	ใครลงทุนสินทรัพย์และกำลังผลิตสูง
MoM / YoY Price	pct_change(1) / pct_change(12)	ราคาเปลี่ยนเร็วเพียงใด
Rolling Average	rolling(6).mean()	ลด Noise เพื่อเห็นแนวโน้ม
Annualized Capacity	Monthly Capacity x 12	เทียบกำลังรองรับรายปี ไม่ใช่ผลผลิตจริง
Dataset Share	Entity / Total in dataset	วัดการกระจุกตัวภายในข้อมูลชุดนี้

ตัวอย่าง Pandas

```
financials = financials.sort_values(['company_name', 'year'])
financials['revenue_growth_pct'] = (
    financials.groupby('company_name')['revenue_usd_bn']
    .pct_change().mul(100)
)
financials['rd_intensity_pct'] = (
    financials['rd_spend_usd_bn']
    / financials['revenue_usd_bn'] * 100
)
```

หาก Revenue เท่ากับศูนย์ ให้เปลี่ยนผลลัพธ์จากการหารเป็น Missing value ไม่ใช่ Infinity

8. ขั้นที่ 7 - Exploratory Data Analysis

EDA ควรเริ่มจากภาพรวม แล้วจึง Drill-down ไปยังบริษัท ผลิตภัณฑ์ ประเทศ และเหตุการณ์

ลำดับ	หัวข้อ EDA	คำถามหลัก
1	Industry Overview	รายได้และกำไรกระจายตาม Segment อย่างไร
2	AI Boom	ก่อนและหลังปี 2022 แตกต่างกันเพียงใด
3	Value Chain	ผู้สร้างรายได้สูงเป็นผู้ลงทุนสูงด้วยหรือไม่
4	Price Cycle	DDR4, NAND, HBM3, H100 และ B200 เปลี่ยนอย่างไร
5	Capacity	Leading-edge และ Memory กระจุกตัวที่ใด
6	Policy Timeline	เหตุการณ์นโยบายเกิดใกล้จุดเปลี่ยนของข้อมูลหรือไม่

ข้อกำหนดการเปรียบเทียบราคา

- DDR4 และ NAND อาจแสดงร่วมกันได้ เพราะใช้ USD/chip
- HBM3 ต้องแสดงแยก เพราะใช้ USD/stack
- H100 และ B200 อาจแสดงแนวโน้มร่วมกันได้ เพราะใช้ USD/unit
- ไม่ควรรวมผลิตภัณฑ์ทั้งห้าบนแกน Y เดียวแล้วเปรียบเทียบราคาดิบ

Models & Algorithms ในภาพ Workflow ไม่จำเป็นต้องหมายถึง **Machine Learning** สำหรับ Project นี้สามารถแทนด้วย **Metric calculations, segmentation, ranking** และ **rule-based quadrants** ซึ่งทำได้ด้วย **Pandas**

9. ชั้นที่ 8 - Matplotlib Visual Storytelling

กราฟหลักประมาณ 6-8 รูปเพียงพอ โดยทุกกราฟต้องตอบคำถามหนึ่งข้อและมีข้อความ Insight ประกอบ

ลำดับ	กราฟในแผ่น	สารนิเทศการสื่อ
1	รายได้รวมตาม Segment	ส่วนใดของห่วงโซ่เติบโต
2	Revenue trend ของบริษัทหลัก	การเติบโตกระจุกตัวหรือไม่
3	Revenue Growth vs R&D; Intensity	การลงทุนสัมพันธ์กับการเติบโตหรือไม่
4	Revenue vs Operating Margin Quadrant	ขนาดกับประสิทธิภาพแตกต่างกันอย่างไร
5	HBM3 Price Trend	ราคา Memory สำหรับ AI เปลี่ยนอย่างไร
6	H100 vs B200 Price Trend	วงจรผลิตภัณฑ์และราคาทดแทน
7	Leading-edge Capacity by Country	ความเสี่ยงจากการกระจุกตัวเชิงพื้นที่
8	Price with Policy Timeline	ให้บริบทเหตุการณ์โดยไม่อ้างเหตุและผล

มาตรฐานทุกกราฟ

- ชื่อกราฟต้องสื่อ Insight ไม่ใช่เพียงชื่อคอลัมน์
- แกนและหน่วยชัดเจน พร้อม Legend ที่อ่านง่าย
- ใช้ชุดสีเดียวกันตลอดทั้ง Project
- ระบุ Source note และ Estimated/Forecast เมื่อเกี่ยวข้อง
- บันทึกเป็น PNG 300 DPI ด้วย bbox_inches='tight'

```
plt.savefig(
    '../figures/01_revenue_by_segment.png',
    dpi=300,
    bbox_inches='tight'
)
```

10. ชั้นที่ 9 - Insight, Limitation และ Recommendation

ทุก Insight ควรเขียนตามโครงสร้าง Observation - Evidence - Interpretation - Limitation

ตัวอย่าง

Observation: รายได้ของกลุ่ม Fabless GPU เพิ่มขึ้นอย่างรวดเร็วหลังปี 2022

Evidence: รายได้ NVIDIA ใน Dataset เพิ่มขึ้นจาก 26.12 พันล้าน USD ในปี 2022 เป็น 130.48 พันล้าน USD ในปี 2024

Interpretation: การเติบโตที่สัมพันธ์กับ AI ใน Dataset กระตุ้นตัวสูงในผู้ให้บริการ GPU

Limitation: ตัวเลขบางปีอาจเป็นค่าจำลองหรือประมาณการและต้องตรวจสอบกับงบจริง

ข้อจำกัดสำคัญที่ต้องเปิดเผย

- Financials ปีหลังและอัตราส่วนบางรายการมีรูปแบบคล้ายข้อมูลคำนวณ
- Chip prices ไม่มีนิยามว่าเป็น Spot, Contract, Retail หรือ ASP
- Export-control severity ไม่มีเกณฑ์และมีข้อมูลรัฐบาลไม่สอดคล้องอย่างน้อยหนึ่งรายการ
- Fab capacity ไม่ระบุ wafer size, utilization, fab ID หรือสถานะโครงการ
- AI shipments, ASP และ revenue ระบุว่าเป็น estimated
- ความสัมพันธ์ตามเวลาไม่เท่ากับเหตุและผล

หากใช้ Dataset นี้โดยไม่ตรวจสอบแหล่งจริง ควรเรียกงานว่า Dataset-based exploratory analysis ไม่ใช่รายงานสถานการณ์อุตสาหกรรมอย่างเป็นทางการ

11. ขั้นที่ 10 - README และการเผยแพร่บน GitHub

README คือรายงานหลักของ Repository ต้องทำให้ผู้อ่านเข้าใจคำถาม วิธีวิเคราะห์ ผลลัพธ์ และข้อจำกัดโดยไม่จำเป็นต้องเปิดทุก Notebook

โครงสร้าง README

- Executive Summary
- Research Question และ Why This Matters
- Dataset และ Data Quality
- Methodology และ Key Metrics
- Key Findings พร้อมภาพจาก figures/
- Strategic Implications
- Repository Structure และ How to Reproduce
- Tools Used, Data Source, Disclaimer และ Author

ตัวอย่างลำดับ Commit

```
chore: initialize project structure
data: add raw semiconductor datasets
analysis: add initial data quality audit
feat: add preprocessing workflow
feat: add financial and price metrics
analysis: complete exploratory analysis
docs: add methodology and limitations
docs: publish final project report
```

GitHub Publication Checklist

- ไม่มี Absolute path, API key, Password หรือข้อมูลส่วนตัว
- Notebook รันใหม่จากต้นฉบับได้โดยไม่ Error
- ภาพทั้งหมดอยู่ใน figures/ และ README แสดงได้
- มี requirements.txt, LICENSE, Data source และ Disclaimer
- ระบุ Estimated/Forecast และข้อจำกัดอย่างชัดเจน
- ไม่มีข้อสรุปเชิงสาเหตุเกินหลักฐาน
- ชื่อไฟล์ Commit message และโครงสร้าง Repository อ่านเข้าใจง่าย

12. วิธีใช้ Codex ใน Visual Studio Code

แบ่งงานเป็นชิ้นเล็ก ๆ และตรวจสอบผลทุกครั้ง ไม่สั่งให้สร้าง Project ทั้งหมดใน Prompt เดียว

Prompt 1 - Data Audit

Inspect the CSV files in data/raw without modifying them. Create a data quality report showing shape, columns, data types, missing values, duplicates, unique categories, numeric ranges, and possible primary-key duplicates. Use only pandas. Do not make assumptions about column meanings.

Prompt 2 - Preprocessing

Create notebooks/02_data_preprocessing.ipynb. Load all files using relative paths. Convert date and numeric columns safely, validate primary keys, preserve raw values, and save cleaned outputs to data/processed. Do not delete suspicious rows automatically. Report each issue and explain every transformation.

Prompt 3 - Feature Engineering

Add reproducible pandas calculations for revenue growth, R&D intensity, CapEx intensity, monthly and yearly price changes, annualized wafer capacity, and dataset-level shares. Handle division by zero explicitly and validate the results.

Prompt 4 - Visualization

Create publication-quality Matplotlib charts for the approved research questions. Use consistent colors, readable labels, units, source notes, and save every figure as a 300-DPI PNG under figures/. Do not use seaborn.

Prompt 5 - Final Review

Review the complete repository for reproducibility and analytical accuracy. Check relative paths, notebook execution order, incorrect units, unsupported causal claims, missing limitations, and broken README image links. Report issues before changing files.

13. Final Deliverables

Deliverable	รายละเอียด	สถานะปัจจุบัน
PROJECT_PLAN.md	คำถาม ขอบเขต KPI และข้อจำกัด	ตอบโจทย์ได้ด้วยข้อมูล
Data Audit	รายงานคุณภาพทุกไฟล์	ปัญหาสำคัญถูกบันทึก
Processed Data	ข้อมูลสะอาดและมี Validation	สร้างซ้ำได้จาก Raw data
EDA Notebooks	ตาราง Metric และการสำรวจ	ทุกผลลัพธ์เชื่อมกับคำถาม
Figures	กราฟ Matplotlib 6-8 รูป	หน่วย Source และคำเตือนครบ
README	รายงานหลักและภาพ Storytelling	ผู้อ่านเข้าใจได้โดยไม่เปิด Notebook
GitHub Repository	Public และทำซ้ำได้	Clone แล้วรันตามคำแนะนำได้

ข้อเสนอแนะสุดท้าย

สำหรับ Mid-Term ให้ใช้ Dataset นี้ในฐานะ Dataset-based exploratory project และระบุข้อจำกัดโดยตรงไปตรงมา หากต้องการใช้เป็น Portfolio ระยะยาว ควรตรวจตัวเลขหลักกับ Annual Report, SEC filing หรือแหล่งอุตสาหกรรมที่เชื่อถือได้ก่อนสรุปเป็นข้อเท็จจริง

Reference

ตัวอย่างรุ่นก่อน: https://github.com/sittidetw/dads5001_hiv_strategic_analysis